

**Analisis Preskriptif Kualitas Air Menggunakan *Natural
Gradient Boosting* dan *Counterfactual explanations***

Proposal Tugas Akhir

Kelas MK Penulisan Proposal (CCH4A3)

103062300095

AFLAH ZAKI SIREGAR



Program Studi Sarjana Teknologi Informasi

Fakultas Informatika

Universitas Telkom

Jakarta

2026

Lembar Persetujuan

**Analisis Preskriptif Kualitas Air Menggunakan *Natural Gradient*
*Boosting dan Counterfactual explanations***

***Prescriptive Analysis of Water quality Using Natural Gradient
Boosting and Counterfactual explanations***

NIM :103062300095

NAMA: AFLAH ZAKI SIREGAR

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana S1 Teknologi Informasi
Fakultas Informatika Universitas Telkom

Jakarta, 14 Juni 2026

Menyetujui

Calon Pembimbing 1



Nurul Ilmi, S.Kom., M.T.
NIP: 25930029S

Calon Pembimbing 2



Rana Zaini Fathiyana, S.ST., M.T.
NIP: 23950035

ABSTRAK

Kualitas air minum yang memenuhi standar kelayakan merupakan aspek fundamental dalam menjaga kesehatan masyarakat. Penelitian terdahulu menunjukkan bahwa berbagai algoritma *machine learning* seperti XGBoost dan Random Forest mampu mengklasifikasikan kelayakan air dengan akurasi tinggi, namun pendekatan-pendekatan tersebut hanya menghasilkan label prediksi tanpa menyertakan estimasi ketidakpastian maupun rekomendasi tindakan perbaikan yang dapat ditindaklanjuti secara operasional. Kesenjangan antara kemampuan prediktif dan kebutuhan preskriptif di lapangan menjadi urgensi utama yang belum terjawab oleh literatur yang ada. Penelitian ini bertujuan untuk menganalisis kerangka kerja analisis preskriptif yang mengintegrasikan Natural Gradient Boosting (NGBoost) dengan Diverse Counterfactual Explanations (DiCE) pada klasifikasi kelayakan air minum. NGBoost digunakan untuk memodelkan distribusi probabilitas kelayakan air melalui distribusi Bernoulli dan Natural Gradient, sedangkan DiCE diterapkan pada model terlatih untuk membangkitkan rekomendasi actionable recourse bagi sampel tidak layak dengan mempertimbangkan properti validity, proximity, sparsity, diversity, dan feasibility. Analisis komparatif dilakukan terhadap baseline deterministik (XGBoost dan Random Forest) menggunakan dataset Water Potability publik dengan evaluasi metrik klasifikasi (Accuracy, Precision, Recall, F1-Score) dan kalibrasi probabilitas (NLL, ECE). Dihipotesiskan bahwa NGBoost mampu menghasilkan performa klasifikasi setara atau lebih baik dibandingkan baseline deterministik dengan kalibrasi probabilistik yang superior, serta DiCE mampu menghasilkan rekomendasi counterfactual dengan validity rate di atas 90% dan feasibility rate di atas 85% sesuai constraint domain kualitas air.

Kata Kunci: analisis preskriptif, Natural Gradient Boosting, counterfactual explanations, kualitas air minum, prediksi probabilistik, actionable recourse

Daftar Isi

Lembar Persetujuan.....	1
ABSTRAK.....	i
Daftar Isi.....	ii
BAB I.....	1
Pendahuluan.....	1
1.1. Latar Belakang.....	1
1.2. Perumusan Masalah	3
1.3. Tujuan.....	3
1.4. Rencana Kegiatan	4
1.5. Jadwal Kegiatan.....	5
BAB II KAJIAN PUSTAKA.....	6
2.1 Penelitian Terdahulu	6
2.2 Landasan Teori	11
2.2.1 <i>Machine learning</i> untuk Kualitas Air.....	11
2.2.2 Kualitas Air dan Parameter Fisikokimia.....	12
2.2.3 NGBoost.....	13
2.2.4 <i>Explainable AI</i> dan <i>Counterfactual explanations</i>	15
2.2.5 DiCE.....	16
2.2.6 Evaluasi Model.....	17
2.3 Gap Penelitian	18
BAB III	19
Metodologi dan Desain Sistem.....	19
3.1. Jadwal Gambaran Umum Alur Pemodelan	19
3.2. Pengumpulan Data	23
3.3. Preprocessing Data	23
3.3.1. Exploratory Data Analysis (EDA).....	24
3.3.2. Penanganan <i>Missing values</i>	24
3.3.3. Train-Test Split	25
3.3.4. Feature scaling	25
3.3.5. Penanganan <i>Class imbalance</i>	25
3.4. Pemodelan NGBoost.....	25
3.4.1. Konfigurasi Model NGBoost.....	25

3.4.2.	Distribusi Output untuk Klasifikasi Biner	26
3.4.3.	Konfigurasi dan Training.....	26
3.4.4.	Proses Training dan Prediksi.....	27
3.4.5.	Baseline Model	27
3.5.	Implementasi Diverse <i>Counterfactual explanations</i>	28
3.5.1.	Konfigurasi DiCE	28
3.5.2.	Konfigurasi Constraints Domain.....	29
3.5.3.	Proses Generate Counterfactual.....	30
3.5.4.	Evaluasi Model Prediktif.....	31
3.5.5.	Evaluasi Counterfactual.....	31
3.6.	Tools dan Lingkungan Pengembangan.....	32
DAFTAR PUSTAKA.....		34
LAMPIRAN		37

BAB I

Pendahuluan

1.1. Latar Belakang

Kualitas air minum yang memenuhi standar kelayakan merupakan aspek fundamental dalam menjaga kesehatan masyarakat sekaligus mendukung keberlanjutan ekosistem perairan. Menurut laporan WHO, UNICEF, dan World Bank (2022), meskipun 74% populasi dunia (5,8 miliar orang) telah mengakses air minum yang dikelola secara aman pada tahun 2020, masih terdapat 2 miliar orang yang belum memiliki akses terhadap layanan air minum yang aman. Di Indonesia, tantangan serupa dihadapi oleh Perusahaan Daerah Air Minum (PDAM) yang mengalami keterbatasan infrastruktur sehingga hanya mampu melayani sebagian kecil rumah tangga di wilayah layanannya [1]. Kondisi ini menegaskan kebutuhan akan sistem evaluasi kualitas air yang tidak hanya akurat dalam memprediksi kelayakan, tetapi juga mampu memberikan rekomendasi perbaikan yang spesifik dan dapat ditindaklanjuti oleh operator pengolahan air. Penentuan kelayakan konsumsi air bergantung pada analisis komprehensif terhadap berbagai parameter fisikokimia, seperti tingkat keasaman (pH), tingkat kekeruhan (turbidity), dan padatan terlarut (total dissolved solids) [2]. Parameter-parameter tersebut saling memengaruhi secara kompleks, sehingga status kelayakan air tidak dapat ditentukan melalui pendekatan sederhana dan memerlukan analisis data yang lebih mendalam. Parameter fisikokimia dipilih sebagai fokus analisis karena bersifat controllable dan actionable, yaitu nilainya dapat diintervensi secara langsung melalui proses pengolahan air seperti koagulasi, filtrasi, aerasi, dan disinfeksi [2], [3]. Karakteristik ini menjadikan parameter fisikokimia sesuai dengan kebutuhan analisis preskriptif berbasis counterfactual, yang memerlukan fitur-fitur yang secara operasional dapat dimodifikasi untuk mencapai kondisi target yang diinginkan. Selain itu, karakteristik data kualitas air yang bersifat multidimensi dan tidak selalu stabil menyebabkan proses pemodelan menjadi lebih menantang, terutama ketika terdapat variasi nilai yang tinggi antar sampel [4].

Variabilitas pada data parameter fisikokimia umumnya bersumber dari perbedaan kondisi lingkungan pada saat pengambilan sampel serta keterbatasan presisi pengukuran. Dalam representasi data tabular, kondisi tersebut sering termanifestasi sebagai derau (*noise*), nilai yang hilang (*missing values*), ketidakseimbangan kelas (*class imbalance*), serta sebaran nilai yang tidak merata, yang secara kolektif dapat memengaruhi kualitas pembelajaran model [5], [4], [6]. Ketidakempurnaan data ini menciptakan tingkat ketidakpastian (*uncertainty*) yang signifikan, sehingga model *machine learning* konvensional yang bersifat

deterministik sering kesulitan membedakan pola yang valid dari variasi data yang bersifat acak [7]. Akibatnya, prediksi yang dihasilkan berisiko menjadi kurang konsisten dan kurang andal untuk digunakan sebagai dasar pengambilan keputusan dalam penentuan kelayakan air minum.

Untuk mengatasi kompleksitas data tersebut, berbagai algoritma *machine learning* berbasis ensemble telah banyak diterapkan dalam pemantauan kualitas air. Park et al. (2022) mengimplementasikan ensemble learning dengan SHAP dan mencapai akurasi ~80% [3]. Patel et al. (2022) menerapkan RF, XGBoost, Gradient boosting pada dataset Water Potability dari Kaggle yang identik dengan penelitian ini, memperoleh akurasi tertinggi 71% dengan Random Forest [8]. Zhu et al. (2023) mengintegrasikan SMOTE-ENN dengan NGBoost dan menunjukkan AUC-ROC 0.85 [6]. Meskipun algoritma tersebut mampu menghasilkan akurasi kompetitif, keseluruhan pendekatan masih berhenti pada tahap prediktif/diagnostik. Pendekatan explainability post-hoc seperti SHAP dan LIME hanya menjelaskan alasan di balik prediksi, namun tidak memberikan instruksi bagaimana parameter harus diubah untuk memperbaiki kualitas air [9]. Kesenjangan fundamental ini bukan masalah transparansi model, melainkan ketiadaan mekanisme preskriptif yang mampu mentransformasi output prediksi menjadi rekomendasi tindakan operasional.

Selain keterbatasan transparansi, model-model prediktif yang umum digunakan saat ini hanya menghasilkan output berupa label klasifikasi biner tanpa menyertakan estimasi tingkat kepercayaan (*confidence estimation*) terhadap prediksi yang dihasilkan [2], [5]. Ketidakmampuan model dalam mengkuantifikasi ketidakpastian prediksi menjadi hambatan tambahan dalam pengambilan keputusan berisiko. Lebih lanjut, informasi berupa label klasifikasi akhir tersebut tidak memberikan instruksi spesifik mengenai parameter apa yang harus diubah guna meningkatkan status kualitas air menjadi layak konsumsi [9]. Kesenjangan antara kemampuan prediktif dengan kebutuhan operasional ini menunjukkan adanya kebutuhan mendesak akan analisis preskriptif yang mampu memberikan rekomendasi tindakan yang dapat ditindaklanjuti (*actionable recourse*). Pendekatan *counterfactual explanations* telah diidentifikasi sebagai solusi yang relevan untuk mengatasi permasalahan tersebut, dengan cara mengidentifikasi perubahan minimal pada fitur input yang diperlukan untuk mencapai hasil target yang diinginkan [10], [11].

Ketidakpastian yang melekat pada data fisikokimia serta keterbatasan transparansi pada model prediktif menciptakan hambatan yang signifikan dalam implementasi sistem pendukung keputusan yang andal [9]. Upaya untuk mengatasi permasalahan ini memerlukan pendekatan terintegrasi yang tidak hanya mampu mengkuantifikasi tingkat ketidakpastian data secara probabilistik, tetapi juga mampu mengubah hasil prediksi tersebut menjadi rekomendasi tindakan yang konkret [7], [10]. Sinergi antara kemampuan estimasi probabilitas dan analisis preskriptif diharapkan dapat menutup kesenjangan antara akurasi teknis model

dengan kebutuhan operasional di lapangan. Dengan demikian, pengembangan kerangka kerja yang menggabungkan aspek ketidakpastian prediksi dan transparansi rekomendasi menjadi urgensi utama untuk meningkatkan efektivitas manajemen kualitas air.

Untuk menjawab kebutuhan tersebut, penelitian ini mengusulkan kerangka kerja analisis preskriptif yang mengintegrasikan algoritma *Natural Gradient Boosting* (NGBoost) [7] untuk kuantifikasi ketidakpastian probabilistik dengan *Diverse Counterfactual explanations* (DiCE) [10] untuk menghasilkan rekomendasi perbaikan kualitas air yang dapat ditindaklanjuti. Pendekatan ini bertujuan untuk menghasilkan output yang tidak hanya akurat secara statistik, tetapi juga transparan dan dapat dipertanggungjawabkan secara logika operasional bagi pengguna akhir. Validasi kerangka kerja yang diusulkan akan dilakukan menggunakan dataset publik kualitas air berformat tabular [8], [12] untuk menguji efektivitas model dalam menangani variabilitas data sekaligus memberikan instruksi perbaikan yang realistis. Dengan demikian, penelitian ini diharapkan dapat memberikan kontribusi berupa sistem pendukung keputusan yang mampu memitigasi risiko kesalahan klasifikasi sekaligus menyediakan panduan preskriptif dalam manajemen kualitas air.

1.2. Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, teridentifikasi tiga kesenjangan utama yang menjadi fokus penelitian ini: (1) ketiadaan estimasi ketidakpastian pada model *machine learning* deterministik yang digunakan di domain kualitas air, (2) ketiadaan mekanisme preskriptif yang mampu mentransformasi output prediksi menjadi rekomendasi tindakan operasional untuk perbaikan kualitas air, dan (3) belum adanya implementasi counterfactual explanations pada data fisikokimia air meskipun potensinya telah diidentifikasi dalam systematic review. Berdasarkan tiga kesenjangan tersebut, dirumuskan pertanyaan penelitian sebagai berikut:

1. Bagaimana performa NGBoost dalam memodelkan kelayakan air secara probabilistik dibandingkan baseline deterministik (XGBoost, RF) berdasarkan metrik klasifikasi dan kalibrasi?
2. Bagaimana implementasi DiCE pada model NGBoost untuk menghasilkan rekomendasi preskriptif yang mengubah status air dari tidak layak menjadi layak?
3. Sejauh mana kualitas rekomendasi counterfactual memenuhi properti validity, proximity, sparsity, diversity, feasibility, serta bagaimana trade-off antar properti tersebut?

1.3. Tujuan

1. Menganalisis performa NGBoost secara komparatif terhadap baseline (XGBoost, RF) dari metrik klasifikasi (Accuracy, Precision, Recall, F1) dan kalibrasi (NLL, ECE).
2. Mengimplementasikan DiCE pada model NGBoost untuk

menghasilkan rekomendasi perubahan parameter fisikokimia yang mengubah status air.

3. Menganalisis kualitas counterfactual berdasarkan validity, proximity, sparsity, diversity, feasibility, termasuk trade-off antar properti dalam constraint domain kualitas air.

1.4. Rencana Kegiatan

Rencana kegiatan penelitian ini terdiri atas enam tahapan utama.

1. Tahap Studi Literatur

Dilakukan kajian teori mengenai pembelajaran mesin probabilistik, khususnya algoritma *Natural Gradient Boosting* (NGBoost), serta metode *Diverse Counterfactual explanations* (DiCE) dan konsep *Explainable Artificial Intelligence* (XAI). Selain itu, dilakukan identifikasi dataset publik kualitas air yang sesuai dengan ruang lingkup penelitian.

2. Tahap Pengumpulan dan Pengolahan Data

Dilakukan akuisisi dataset sekunder berformat tabular yang mencakup parameter fisikokimia air, serta proses pembersihan data, penanganan nilai yang hilang, dan eksplorasi karakteristik statistik untuk memastikan kesiapan data dalam pemodelan.

3. Tahap Pemodelan Probabilistik

Dilakukan pembangunan model prediksi kelayakan air minum menggunakan algoritma NGBoost dengan konfigurasi parameter yang menghasilkan estimasi probabilitas untuk mengkuantifikasi ketidakpastian prediksi.

4. Tahap Implementasi Rekomendasi Preskriptif

Dilakukan penerapan metode DiCE pada model yang telah terlatih untuk menghasilkan rekomendasi counterfactual, yaitu instruksi perubahan nilai parameter fisikokimia spesifik guna meningkatkan status kelayakan air.

5. Tahap Pengujian dan Evaluasi

Dilakukan evaluasi performa model dalam menangani ketidakpastian data, serta pengujian kualitas rekomendasi DiCE berdasarkan properti *feasibility*, *proximity*, dan *diversity*.

6. Tahap Penyusunan Laporan

Dilakukan dokumentasi seluruh proses penelitian dalam bentuk laporan Tugas Akhir sebagai pertanggungjawaban akademik.

1.5. Jadwal Kegiatan

Tabel 1.1: Jadwal kegiatan proposal tugas akhir

NO	Kegiatan	Bulan ke-																							
		1				2				3				4				5				6			
1.	Studi Literatur																								
2.	Pengumpulan dan Pengolahan Data																								
3.	Pemodelan NGBoost																								
4.	Implementasi DiCE																								
5.	Pengujian dan Evaluasi Hasil																								
6.	Penyusunan Laporan																								

BAB II

KAJIAN PUSTAKA

2.1 Penelitian Terdahulu

Kualitas air merupakan aspek krusial dalam menjaga kesehatan masyarakat dan keberlanjutan ekosistem. Parameter fisikokimia seperti *pH*, kekerasan (*hardness*), total padatan terlarut, kloramin, sulfat, konduktivitas, karbon organik, trihalometana, dan turbiditas digunakan secara luas untuk menentukan kelayakan air minum [2]. Dalam beberapa tahun terakhir, pemanfaatan *machine learning* untuk analisis kualitas air berkembang pesat, namun sebagian besar pendekatan yang ada masih berorientasi prediktif semata tanpa memberikan rekomendasi perbaikan yang dapat dioperasionalkan.

Aslam et al. memanfaatkan hybrid *machine learning* berbasis kombinasi neural network dan XGBoost untuk manajemen kualitas air pada sungai Indus [2]. Hasil yang diperoleh menunjukkan performa klasifikasi yang memadai dalam mengkategorikan kualitas air. Namun, pendekatan tersebut hanya berhenti pada tahap prediktif tanpa dilengkapi mekanisme *explainability* maupun rekomendasi tindakan perbaikan. Akibatnya, gap antara hasil prediksi dan keputusan operasional untuk meningkatkan kualitas air tidak terjembatani.

Sejalan dengan itu, Park et al. (2022) mengembangkan model ensemble untuk penilaian kualitas air dengan memanfaatkan berbagai algoritma *machine learning* [3]. Dilakukan evaluasi komparatif untuk menentukan kombinasi model yang optimal dalam mengklasifikasikan kelayakan air. Meskipun berhasil memberikan baseline yang kuat bagi domain kualitas air, pendekatan ensemble tersebut bersifat deterministik dan tidak dilengkapi dengan modul *Explainable AI*. Keterbatasan ini mengakibatkan model sulit diinterpretasikan oleh praktisi lapangan dalam konteks pengambilan keputusan.

Berbeda dengan pendekatan prediktif konvensional, Al Bataineh et al. (2026) mengimplementasikan XGBoost yang dikombinasikan dengan feature-based neural network untuk prediksi *Water quality Index* (WQI) menggunakan dataset Water Potability dari Kaggle yang identik dengan dataset pada penelitian ini [5]. Analisis feature importance dilakukan menggunakan SHAP untuk memberikan *explainability post-hoc* terhadap prediksi model. Hasil yang diperoleh menunjukkan kemampuan XGBoost dalam menghasilkan prediksi deterministik yang akurat dengan interpretasi fitur yang transparan. Namun, *explainability* yang diberikan oleh SHAP bersifat pasif, yaitu hanya menjelaskan alasan di balik prediksi tanpa memberikan instruksi preskriptif mengenai langkah-langkah konkret untuk mengubah status air dari tidak layak menjadi layak. Dengan demikian, gap antara pemahaman model dan tindakan korektif masih terbuka.

Dalam konteks *Explainable AI* untuk domain air, Aderemi et al. (2025) melakukan systematic review terhadap berbagai pendekatan XAI yang diterapkan

pada pemantauan kualitas air [9]. Dilakukan klasifikasi dan analisis mendalam terhadap metode *explainability*, termasuk LIME, SHAP, dan *counterfactual explanations*. Ditemukan bahwa *counterfactual explanations* memiliki potensi signifikan untuk menjawab pertanyaan *what-if* dalam konteks kualitas air. Meskipun demikian, review tersebut bersifat teoritis dan belum dilengkapi dengan implementasi spesifik counterfactual pada dataset fisikokimia air. Selain itu, *feasibility* constraints yang bersumber dari standar regulasi air, seperti guideline WHO, belum diintegrasikan secara eksplisit dalam pembahasan counterfactual.

Di luar domain kualitas air, Nnadi et al. (2026) mengembangkan framework multi-level XAI untuk prediksi risiko depresi pada mahasiswa dengan memanfaatkan DiCE (Diverse Counterfactual explanations) [10]. Dibangun arsitektur counterfactual yang mampu menghasilkan rekomendasi alternatif dengan tingkat keberhasilan yang tinggi. Metodologi yang dikembangkan memberikan kerangka acuan implementasi DiCE yang komprehensif, meliputi pembentukan *feasibility* constraints, diversifikasi output, dan evaluasi multi-level. Namun, karena diterapkan pada domain psikologi dengan fitur demografis dan perilaku, pendekatan tersebut belum diadaptasi untuk parameter fisikokimia yang memiliki constraint domain spesifik berbasis standar kesehatan lingkungan.

Pada domain finansial, Dastile dan Celik (2024) melakukan investigasi teknis terhadap optimasi properti *counterfactual explanations* dalam credit scoring [11]. Dilakukan analisis mendalam terhadap lima properti counterfactual, yaitu *validity*, *proximity*, *sparsity*, *diversity*, dan *feasibility*, dengan mengusulkan metrik kuantitatif untuk mengukur kualitas counterfactual yang dihasilkan. Hasil penelitian tersebut memberikan fondasi teoretis yang kuat bagi evaluasi counterfactual quality. Meskipun demikian, domain credit scoring memiliki karakteristik constraint yang berbeda dengan kualitas air, sehingga adaptasi framework evaluasi ke domain fisikokimia air diperlukan.

Selanjutnya, Lenatti et al. (2025) melakukan evaluasi komparatif antara DiCE dan MUCH (Multiclass Counterfactual Using Support Vector Data Description) untuk klasifikasi multi-class pada data penyakit kronis (COPD) [13]. Dilakukan conformity evaluation untuk mengukur sejauh mana counterfactual yang dihasilkan sesuai dengan distribusi data asli. Penelitian tersebut menunjukkan bahwa DiCE mampu menghasilkan counterfactual yang valid dengan diversifikasi yang memadai untuk kasus multi-class. Namun, penerapan pada klasifikasi biner kualitas air dengan constraint fisikokimia yang mengacu pada standar regulasi masih belum dieksplorasi.

Di samping penelitian-penelitian utama tersebut, terdapat studi pendukung yang memperkuat landasan teknis *counterfactual explanations*. Ferrario dan Loi melakukan analisis robustness counterfactual terhadap perubahan model akibat *retraining*, yang menjadi pertimbangan penting dalam stabilitas rekomendasi preskriptif [14]. Suffian et al. mengembangkan framework FCE (*Feedback-Based Counterfactual explanations*) yang memungkinkan *human-in-the-loop* dalam

proses iterasi counterfactual [15]. Meulemeester et al. memperkenalkan konsep *Counterfactual Feature importance* (CFI) untuk mengkuantifikasi dampak perubahan individual fitur terhadap keluaran dari counterfactual [16]. Sementara itu, Carlevaro et al. (2024) mengusulkan algoritma MUCH dengan *Halton sampling* sebagai alternatif dari DiCE untuk kasus multiclass [17]. Studi-studi tersebut secara kolektif menunjukkan bahwa domain *counterfactual explanations* telah berkembang pesat, namun implementasi terintegrasi dengan model probabilistik seperti NGBoost pada data kualitas air masih merupakan area yang belum terjamah.

Berdasarkan kajian terhadap penelitian-penelitian terdahulu, diketahui bahwa terdapat kesenjangan sistematis antara pendekatan prediktif konvensional dengan kebutuhan preskriptif di lapangan. Tabel 2.1 menyajikan perbandingan komprehensif terhadap penelitian terdahulu berdasarkan taxonomy tiga dimensi, yaitu (1) tipe prediksi, (2) tipe *explainability*, dan (3) orientasi output.

Tabel 2.1: Tabel Perbandingan

Author & Year	Metode ML	Dataset / Domain	Metrik Evaluasi	Tipe Prediksi	Tipe XAI	Orientasi Output	Key Contribution	Gap Penelitian
Aslam et al. (2022)	Hybrid RT-ANN	Indus River, WQI	$R^2 = 0.951$, RMS E = 2.319, NSE = 0.945	Deterministik	Tidak ada	Deskriptif (prediksi WQI)	Hybrid 12 algoritma data-mining untuk prediksi WQI	Hanya prediktif (regresi); tanpa explainability; tanpa rekomendasi preskriptif
Park et al. (2022)	XGBoost + SHAP	Sungai Korea, Chl-a	RMS E = 1.872, RSR = 0.630, NSE = 0.603	Deterministik	Pasif (SHAP)	Diagnostik (interpretasi variabel)	XAI (SHAP) untuk interpretasi model ensemble prediksi kualitas air	SHAP hanya menjelaskan WHY; tidak memberikan rekomendasi HOW to fix; domain regresi
Al Bataineh et al. (2026)	XGBoost + Feature-Based NN	Public Freshwater Quality	Accuracy: 86.9%, F1: 0.849, AUC: 0.894	Deterministik	Pasif (SHAP)	Diagnostik (feature importance)	Framework hybrid NN-XGBoost dengan inisialisasi bobot berbasis SHAP	Explainability tanpa prescriptive output; SHAP hanya diagnostik

Patel et al. (2022)	RF, XGBoost, GB, DT, SVC	Water Potability (Kaggle)	Accuracy: 81% (RF & GB)	Deterministik	Tidak ada	Deskriptif (klasifikasi biner)	Perbandingan 5 algoritma ML pada dataset Water Potability + LIME	Dataset identik; hanya prediktif tanpa rekomendasi preskriptif
Yurtsever & Emeç (2023)	RF, XGBoost, Adaboost, SVR-XGB Hybrid	Water Potability (Kaggle)	Accuracy: 99.4%, F1: 99.4% (SVR-XGB Hybrid)	Deterministik	Tidak ada	Deskriptif (klasifikasi + regresi)	Hybrid SVR-XGBoost dengan hyperparameter tuning Gridsearch/Randomsearch	Dataset identik; akurasi tinggi tanpa uncertainty estimation dan tanpa preskriptif
Aderemi et al. (2025)	Systematic Review	Water Quality (Review)	— (review paper)	—	Teoritis (Counterfactual)	Teoritis (Preskriptif)	Legitimasi XAI termasuk counterfactual untuk domain air	Belum ada implementasi counterfactual spesifik pada fisikokimia air
Nnadi et al. (2026)	Random Forest + SHAP + H-LIME + DiCE	Student Depression Risk (27.901 sampel)	Accuracy: 0.839, ROC-AUC: 0.916	Deterministik	Aktif (DiCE)	Preskriptif (rekomendasi perubahan)	Multi-level XAI: global (SHAP) + subgroup (H-LIME) + individual (DiCE)	Domain non-air; constraint berbeda dengan parameter fisikokimia
Dastile & Celik (2024)	Counterfactual Optimization	Credit Scoring	AUC model: 0.71 (NN); CF: analisis 5 properti	Deterministik	Aktif (Counterfactual)	Preskriptif (optimasi properti CF)	Optimasi simultan 5 properti counterfactual (validity, sparsity, proximity, diversity, feasibility)	Domain finansial; constraint berbeda dengan kualitas air

							y)	
Zhu et al. (2023)	SMOTE-ENN + NGBost	Corporate Financial Risk	Accuracy: 97.18 %	Probabilistik	Tidak ada	Prediktif probabilistik	Integrasi SMOTE-ENN dengan NGBost untuk data class imbalance	Probabilistik tanpa prescriptive; domain non-air
Duan et al. (2020)	NGBost	Benchmark UCI Regression/Classification	Competitive NLL, CRPS vs MC Dropout & Deep Ensembles	Probabilistik	Tidak ada	Prediktif probabilistik	Paper foundational NGBost ; Natural Gradient pada ruang distribusi parametrik	Foundational; tanpa prescriptive output; domain general
Penelitian Ini	NGBost + DiCE	Water Potability (Kaggle)	Target : $F1 \geq$ baseline, $ECE < 0.1$, Validity $> 90\%$	Probabilistik	Aktif (DiCE)	Preskriptif	Integrasi model probabilistik + prescriptive counterfactual pada domain air dengan constraints Permenkes/WHO	Mengisi gap: first practical implementasi on probabilistik + preskriptif pada domain kualitas air

Dari Tabel 2.1 terlihat bahwa penelitian di domain kualitas air, seperti yang dilakukan oleh Aslam et al. [2], Park et al. [3], dan Al Bataineh et al. [5], dominan berada pada kuadran deterministik-pasif-deskriptif. Pada dataset Water Potability yang identik dengan penelitian ini, Patel et al.[8] mencapai akurasi 81% dan Yurtsever & Emeç [12] mencapai akurasi 99.4% dengan hybrid SVR-XGBoost, namun keduanya tetap berhenti pada tahap prediktif tanpa estimasi ketidakpastian maupun rekomendasi preskriptif. Aderemi et al. [9] membuka arah ke kuadran preskriptif namun masih bersifat teoritis. Di sisi lain, penelitian yang telah

menerapkan counterfactual aktif, seperti Nnadi et al. [10], Dastile dan Celik [11], serta Lenatti et al. [13], berada di domain non-air dengan constraint yang berbeda. Baris Penelitian Ini menunjukkan posisi unik pada kuadran probabilistik-aktif-preskriptif yang sebelumnya tidak terisi oleh penelitian manapun. Dengan demikian, integrasi antara model probabilistik (NGBoost) dengan explainability preskriptif (DiCE) pada domain kualitas air berbasis parameter fisikokimia yang mematuhi feasibility constraints standar regulasi merupakan kontribusi utama yang mengisi gap signifikan pada literatur yang ada.

2.2 Landasan Teori

Berdasarkan kajian terhadap penelitian-penelitian terdahulu, teridentifikasi pola sistematis dalam literatur domain kualitas air: pendekatan deterministik seperti hybrid Neural network-XGBoost [2], ensemble model [3], maupun XGBoost dengan SHAP [5] berhasil memberikan akurasi klasifikasi yang kompetitif, namun ketiadaan kemampuan dalam mengkuantifikasi ketidakpastian prediksi secara probabilistik menjadi kelemahan mendasar dalam konteks pengambilan keputusan berisiko. NGBoost [18], [7] hadir untuk mengisi celah tersebut dengan memodelkan distribusi penuh probabilitas melalui Natural Gradient. Namun, keunggulan probabilistik NGBoost tersebut belum diimbangi dengan kemampuan preskriptif untuk menghasilkan rekomendasi operasional yang dapat ditindaklanjuti. Di sisi lain, DiCE [10] dan framework counterfactual lainnya [11],[13] menyediakan kerangka preskriptif yang mampu menghasilkan rekomendasi perubahan fitur, namun implementasinya pada domain kualitas air yang memiliki feasibility constraints berbasis standar fisikokimia dan regulasi lingkungan masih terbatas. Dengan demikian, sinergi antara NGBoost dan DiCE menjadi fondasi utama penelitian ini untuk menjembatani kesenjangan antara prediksi probabilistik dan rekomendasi preskriptif pada manajemen kualitas air


2.2.1 Machine learning untuk Kualitas Air

Kualitas air minum dievaluasi berdasarkan parameter fisikokimia yang mencerminkan kondisi kimiawi dan sifat fisik air. *Water quality* Index (WQI) digunakan untuk merangkum parameter individual menjadi satu nilai indeks yang merepresentasikan kelayakan air. Namun, pendekatan agregat seperti WQI sering tidak menunjukkan parameter spesifik yang menjadi penyebab ketidaklayakan, sehingga pendekatan *machine learning* pada parameter individual lebih sesuai untuk mendukung analisis yang lebih terarah [2].

Dataset Water Potability yang digunakan pada penelitian ini terdiri atas sembilan parameter fisikokimia, yaitu *pH*, *hardness*, solids, chloramines, sulfate, conductivity, organic carbon, trihalomethanes, dan *turbidity*. Dataset tersebut berbentuk tabular statis dari Kaggle [8], [12] sehingga sesuai untuk analisis prediktif dan preskriptif tanpa melibatkan kompleksitas data real-time berbasis IoT [19]. Parameter-parameter tersebut menjadi dasar dalam membangun model prediksi kelayakan air dan selanjutnya digunakan sebagai input dalam pembentukan rekomendasi perbaikan.

2.2.2 Kualitas Air dan Parameter Fisikokimia

Pemanfaatan *machine learning* untuk analisis kualitas air telah berevolusi seiring ketersediaan dataset multi-parameter dan kebutuhan otomatisasi pengambilan keputusan. Evolusi tersebut mengikuti lintasan dari model klasik yang bersifat deterministik dan tidak scalable, ke gradient boosting yang scalable namun tetap menghasilkan point estimate, hingga probabilistic boosting yang mampu mengkuantifikasi ketidakpastian prediksi secara penuh, sebagaimana diilustrasikan pada Gambar 2.1.



Gambar 2.1 Evolusi Pendekatan *Machine learning* untuk Kualitas Air (Sumber: Diolah dari [7], [3])

Evolusi tersebut tidak terlepas dari tantangan fundamental pada kualitas data. Dataset kualitas air umumnya mengandung nilai yang hilang akibat keterbatasan presisi pengukuran dan kondisi lapangan, sehingga proses imputasi menjadi prasyarat kritis dalam pipeline *machine learning*. Taksonomi metode imputasi untuk data biomedis telah membandingkan berbagai pendekatan seperti MICE, MissForest, dan GAIN, di mana MICE terbukti efektif dalam mempertahankan struktur korelasi multivariat pada data tabular [4]. Karakteristik tersebut relevan untuk diterapkan pada parameter fisikokimia air yang memiliki ketergantungan antar variabel.

Aslam et al. (2022) mengimplementasikan hybrid *machine learning* berbasis kombinasi neural network dan XGBoost untuk klasifikasi WQI pada sungai Indus [2]. Pendekatan tersebut memanfaatkan kekuatan representasi fitur dari neural network dan kemampuan gradient boosting dalam menangani hubungan non-linear antar parameter. Hasil yang diperoleh menunjukkan performa klasifikasi yang memadai, namun model tersebut berada pada kategori point estimate tanpa informasi ketidakpastian, sejalan dengan karakteristik gradient boosting konvensional pada kolom (b) Gambar 2.1.

Park et al. (2022) mengembangkan model ensemble yang menggabungkan berbagai algoritma *machine learning* untuk penilaian kualitas air [3]. Pendekatan ensemble tersebut berhasil memberikan baseline yang kuat, namun tetap bersifat

deterministik dan tidak dilengkapi dengan mekanisme *explainability*. Akibatnya, model sulit diinterpretasikan oleh praktisi lapangan dalam menentukan parameter mana yang perlu dikoreksi jika prediksi menunjukkan ketidaklayakan.

Al Bataineh et al. (2026) menerapkan XGBoost yang dikombinasikan dengan feature-based neural network pada dataset Water Potability yang identik dengan dataset pada penelitian ini [5]. XGBoost dipilih karena kemampuannya dalam menangani *missing values*, mengimplementasikan regularisasi untuk mencegah overfitting, dan memberikan feature importance yang transparan melalui SHAP. Namun, seperti yang ditunjukkan pada Gambar 2.1 kolom (b), XGBoost hanya menghasilkan probabilitas titik yang tidak mencerminkan distribusi penuh ketidakpastian prediksi.

Kelemahan fundamental dari pendekatan deterministik, seperti yang diimplementasikan oleh Aslam et al. [2], Park et al. [3], dan Al Bataineh et al. [5], terletak pada ketidakmampuannya mengkuantifikasi ketidakpastian inheren pada data fisikokimia air. Parameter seperti *pH* dan turbiditas memiliki variabilitas alami akibat faktor lingkungan dan musiman, sehingga prediksi tunggal tanpa interval kepercayaan dapat menyesatkan pengambil keputusan. Selain itu, ketiga pendekatan tersebut berhenti pada tahap prediktif tanpa memberikan rekomendasi operasional untuk perbaikan kualitas air.

Di luar domain air, berbagai penelitian telah menunjukkan keunggulan pendekatan probabilistik dalam menangani ketidakpastian pada data kompleks. Zhu et al. (2023) mengimplementasikan kombinasi SMOTE-ENN dan NGBBoost untuk penilaian risiko finansial, di mana NGBBoost berhasil memberikan distribusi probabilitas penuh yang memungkinkan pengukuran kalibrasi model [6]. Li et al. (2023/2024) menerapkan NGBBoost untuk estimasi State of Charge (SoC) baterai secara probabilistik, menunjukkan kemampuan model dalam menghasilkan prediksi terkalibrasi dengan interval kepercayaan [18]. Studi-studi tersebut memberikan indikasi bahwa pendekatan probabilistik, sebagaimana diilustrasikan pada kolom (c) Gambar 2.1, dapat diadaptasi untuk domain kualitas air, di mana ketidakpastian parameter fisikokimia menjadi karakteristik inheren data.

Berdasarkan kajian tersebut, diketahui bahwa domain kualitas air masih didominasi oleh pendekatan deterministik yang tidak mengakomodasi ketidakpastian prediksi. Gap tersebut menjadi fondasi bagi pemanfaatan NGBBoost sebagai model probabilistik yang mampu menghasilkan distribusi penuh probabilitas kelayakan air, sebagaimana akan dijelaskan pada Subbab 2.2.4.

2.2.3 NGBBoost

Di luar domain kualitas air, *Natural Gradient Boosting* (NGBBoost) telah terbukti efektif dalam berbagai aplikasi prediksi probabilistik. Duan et al. (2020) memperkenalkan NGBBoost sebagai algoritma boosting generik yang memodelkan

distribusi penuh probabilitas dengan memanfaatkan Natural Gradient pada ruang parameter distribusi, menunjukkan performa yang kompetitif pada benchmark regresi dan klasifikasi. Pada domain sumber daya air, NGBoost telah diaplikasikan untuk prediksi probabilitas runoff dengan distribusi lognormal dan normal, di mana model menghasilkan interval kepercayaan yang lebih andal dibandingkan pendekatan deterministik[7]. Lebih lanjut, Li et al. (2024) mengimplementasikan NGBoost untuk estimasi State of Charge (SoC) baterai secara probabilistik, membuktikan kemampuan model dalam menghasilkan prediksi terkalibrasi dengan interval kepercayaan [18]. Zhu et al. (2023) juga mengintegrasikan SMOTE-ENN dengan NGBoost untuk prediksi risiko finansial, di mana pendekatan probabilistik tersebut mampu mengkuantifikasi ketidakpastian pada data dengan kelas tidak seimbang [6]. Namun, meskipun NGBoost telah diadopsi pada berbagai domain, penerapannya pada klasifikasi kelayakan air minum yang dikombinasikan dengan rekomendasi preskriptif counterfactual masih merupakan area yang belum terjamah.

Secara matematis, NGBoost memodelkan distribusi kondisional $P_\theta(y | x)$ dengan parameter distribusi θ yang menjadi target prediksi. Untuk klasifikasi biner, distribusi Bernoulli digunakan dengan parameter $\mu(x) = P(y = 1 | x)$. Fungsi probabilitas Bernoulli dinyatakan sebagai:

$$P(y | x) = \mu(x)^y \cdot (1 - \mu(x))^{1-y}$$

dengan $y \in \{0, 1\}$ dan $\mu(x) = \sigma(f(x))$ merupakan fungsi sigmoid dari output ensemble model. Proses optimasi pada NGBoost menggunakan proper scoring rule, yaitu Negative Log-Likelihood:

$$\mathcal{L}(\theta) = -\mathbb{E}_{y \sim P_\theta} [\log P_\theta(y|x)]$$

Gradient konvensional terhadap parameter θ dihitung sebagai:

$$\nabla \theta = \frac{\partial \mathcal{L}(\theta)}{\partial \theta}$$

Namun, karena parameter distribusi berada pada ruang Riemannian, NGBoost menggunakan Natural Gradient yang diperoleh dengan mengalikan invers Fisher Information Matrix (FIM) terhadap gradient konvensional:

$$I(\theta) = \mathbb{E}_{y \sim P_\theta} [\nabla \theta \log P_\theta(y | x) \cdot \nabla \theta \log P_\theta(y | x)^\top]$$

$$\widetilde{\nabla}_\theta = I(\theta)^{-1} \nabla$$

Update parameter pada iterasi ke- m dilakukan dengan:

$$\theta^{(m)} = \theta^{(m-1)} - \eta \cdot \widetilde{\nabla}_\theta^{(m)}$$

dengan η merupakan learning rate. Penggunaan Natural Gradient memastikan arah update memperhatikan geometri ruang probabilitas, sehingga estimasi parameter distribusi menjadi lebih stabil dan hasil prediksi probabilistik lebih terkalibrasi.

Pendekatan probabilistik pada penelitian ini merujuk secara spesifik pada pemodelan distribusi output menggunakan NGBoost dengan parameterisasi Bernoulli, bukan pada pendekatan Bayesian yang memerlukan posterior inference seperti Bayesian Neural Networks atau Monte Carlo Dropout. Ketidakpastian yang dikuantifikasi bersifat aleatoric, direpresentasikan sebagai $\mu(1-\mu)$ dari distribusi Bernoulli.

NGBoost dipilih sebagai model probabilistik berdasarkan pertimbangan berikut: (1) Bayesian Neural Network memiliki kompleksitas komputasi tinggi untuk dataset tabular berukuran moderat; (2) Monte Carlo Dropout hanya memberikan approximate uncertainty; (3) gradient boosting secara empiris terbukti superior pada data tabular dibandingkan deep learning [7]; (4) NGBoost kompatibel dengan framework DiCE melalui API `predict_proba` untuk optimasi counterfactual berbasis gradient.

2.2.4 Explainable AI dan Counterfactual explanations

Explainable AI (XAI) digunakan untuk membantu memahami alasan di balik hasil prediksi model *machine learning*. Secara umum, XAI dibedakan menjadi pendekatan post-hoc dan preskriptif. Pendekatan post-hoc seperti SHAP dan LIME berfungsi menjelaskan prediksi yang sudah dihasilkan model [9], sedangkan pendekatan preskriptif memberikan arahan perubahan fitur agar hasil prediksi bergeser ke kondisi yang diinginkan [11].

Tabel 2.2 Perbandingan Pendekatan XAI

Metode	Tipe	Output	Kelebihan	Keterbatasan	Relevansi Penelitian Ini
SHAP	Post-hoc, diagnostik	Feature importance values (kontribusi per fitur)	Global + local explanation; model-agnostic	Tidak memberikan rekomendasi aksi, hanya menjawab "mengapa"	Tidak sesuai sebab tidak preskriptif
LIME	Post-hoc, diagnostik	Local linear approximation	Interpretable; model-agnostic	Tidak stabil antar runs; tidak preskriptif;	Tidak sesuai sebab

				tidak actionable	tidak preskriptif
Counterfactual (DiCE)	Preskriptif, aktif	Perubahan fitur spesifik untuk mengubah prediksi	Actionable; diverse; constrained; menjawab "bagaimana mengubah"	Bergantung pada kualitas model; komputasi lebih berat	Sesuai sebab memberikan rekomendasi operasional

Pada penelitian ini, pendekatan preskriptif lebih relevan karena tujuan tidak hanya menjelaskan hasil prediksi, tetapi juga memberikan rekomendasi perbaikan kualitas air. *Counterfactual explanations* digunakan untuk menunjukkan perubahan minimal pada fitur tertentu agar status air bergeser dari tidak layak menjadi layak. Dastile dan Celik (2024) mengidentifikasi lima properti kunci counterfactual, yaitu *validity*, *proximity*, *sparsity*, *diversity*, dan *feasibility*, sebagai fondasi evaluasi kualitas rekomendasi [11]. Aderemi et al. (2025) menunjukkan bahwa pendekatan counterfactual potensial untuk menjembatani prediksi dan tindakan korektif pada domain kualitas air, meskipun implementasi spesifik pada parameter fisikokimia masih belum dilakukan [9].

2.2.5 DiCE

Diverse *Counterfactual explanations* (DiCE) merupakan framework untuk membangkitkan beberapa alternatif counterfactual yang valid, beragam, dan tetap realistis. DiCE dipilih karena mampu menghasilkan rekomendasi yang tidak hanya mengubah prediksi model, tetapi juga mempertimbangkan *feasibility* dan batasan domain [10], [11]. Dalam konteks penelitian ini, DiCE digunakan untuk mencari kombinasi perubahan parameter kualitas air yang dapat mendorong prediksi ke kelas layak tanpa melanggar batas fisikokimia yang telah ditetapkan WHO.

Penerapan DiCE dalam penelitian ini difokuskan pada data tabular kualitas air [8], sehingga fitur yang diubah hanya fitur yang bersifat dapat dimodifikasi, sedangkan fitur yang tidak relevan untuk intervensi tetap dipertahankan [10]. Pendekatan ini membuat hasil counterfactual lebih dapat dipahami dan lebih dekat dengan kondisi operasional [11]. Selain itu, Meulemeester et al. memperkenalkan konsep Counterfactual Feature importance (CFI) untuk mengkuantifikasi dampak perubahan individual fitur terhadap output counterfactual [16], sehingga rekomendasi yang dihasilkan dapat diprioritaskan berdasarkan parameter yang paling berpengaruh.

DiCE dipilih dibandingkan framework counterfactual lain berdasarkan pertimbangan: (1) Wachter's method hanya menghasilkan satu counterfactual; (2)

FACE kurang fleksibel dalam constraints domain-specific; (3) Growing Spheres tidak mendukung multi-objective optimization; (4) DiCE menghasilkan diverse counterfactuals dengan mekanisme permitted_range untuk constraint regulasi; (5) library dice-ml mature dan compatible dengan scikit-learn API.

2.2.6 Evaluasi Model

Evaluasi model pada penelitian ini mencakup tiga aspek: performa klasifikasi, kalibrasi probabilistik, dan kualitas counterfactual.

A. Metrik Klasifikasi:

- (1) $Accuracy = (TP + TN) / (TP + TN + FP + FN)$, mengukur proporsi prediksi benar terhadap total sampel.
- (2) $Precision = TP / (TP + FP)$, mengukur proporsi prediksi positif yang benar.
- (3) $Recall = TP / (TP + FN)$, mengukur proporsi sampel positif yang berhasil dideteksi.
- (4) $F1 - Score = 2 \times (Precision \times Recall) / (Precision + Recall)$, merupakan harmonic mean antara precision dan recall yang memberikan evaluasi seimbang pada dataset tidak seimbang.

B. Metrik Kalibrasi Probabilistik:

- (1) $NLL = -(1/N) \times \sum [y_i \times \ln(\mu_i) + (1 - y_i) \times \ln(1 - \mu_i)]$, mengukur seberapa baik distribusi probabilistik model sesuai dengan label aktual, di mana μ_i adalah probabilitas prediksi dan y_i adalah label sebenarnya
- (2) $NLL = -(1/N) \times \sum [y_i \times \ln(\mu_i) + (1 - y_i) \times \ln(1 - \mu_i)]$, mengukur selisih antara confidence model dengan akurasi aktual pada setiap bin B_m , di mana $acc(B_m)$ adalah akurasi rata-rata dan $conf(B_m)$ adalah confidence rata-rata pada bin tersebut.

C. Metrik Kualitas Counterfactual:

- (1) $Validity Rate = (jumlah\ CF\ valid) / (total\ CF\ yang\ dihasilkan)$, mengukur efektivitas counterfactual dalam mencapai kelas yang diinginkan.
- (2) $Proximity = (1/K) \times \sum ||x_{cf} - x_{original}||$, mengukur jarak rata-rata antara counterfactual dengan instance asli menggunakan norma L1 atau L2.
- (3) $Sparsity = (1/K) \times \sum [||x_{cf} - x_{original}||_0 / d]$, mengukur proporsi rata-rata fitur yang diubah terhadap total fitur d.

(4) *Diversity* = $[1 / (K \times (K - 1))] \times \sum_i \sum_j ||cf_i - cf_j||$,
mengukur variasi antar counterfactual yang dihasilkan untuk satu instance.

(5) *Feasibility Rate* =
(jumlah CF yang memenuhi constraints) / (total CF)
,mengukur proporsi counterfactual yang memiliki nilai fitur dalam rentang yang secara operasional layak dan sesuai dengan standar regulasi yang berlaku.

2.3 Gap Penelitian

Berdasarkan penelitian terdahulu, sebagian besar studi pada domain kualitas air masih berfokus pada prediksi deterministik dan belum memberikan rekomendasi perbaikan yang operasional [2], [3]. Beberapa penelitian telah menerapkan XGBoost dan SHAP, tetapi pendekatannya masih berhenti pada penjelasan prediksi, belum sampai pada tindakan preskriptif [5], [9].

Di sisi lain, penelitian yang menggunakan counterfactual explanations umumnya dilakukan pada domain di luar kualitas air, seperti kesehatan mental, credit scoring, dan penyakit kronis, sehingga penerapannya pada data fisikokimia air masih terbatas [10], [11], [13]. Dengan demikian, penelitian ini memberikan kontribusi sebagai first practical implementation yang mengintegrasikan model probabilistik (NGBoost) dengan mekanisme prescriptive counterfactual (DiCE) pada domain kualitas air minum berbasis parameter fisikokimia, dengan feasibility constraints yang mengacu pada standar WHO Guidelines for Drinking-Water Quality (2022) [20] dan Permenkes No. 2 Tahun 2023 [21].

Penggunaan model deterministik seperti XGBoost pada domain kualitas air tidak mampu mengkuantifikasi ketidakpastian prediksi. Penggunaan SHAP hanya memberikan atribusi fitur tanpa instruksi perubahan yang actionable. Integrasi NGBoost sebagai model probabilistik dengan DiCE sebagai mekanisme preskriptif mengatasi kedua limitasi tersebut secara simultan dalam satu kerangka kerja terintegrasi.


BAB III

Metodologi dan Desain Sistem


Natural Gradient Boosting (NGBoost) dan *Diverse Counterfactual explanations* (DiCE) dipilih dalam penelitian ini karena kemampuannya dalam menghasilkan prediksi probabilistik yang terkalibrasi serta rekomendasi preskriptif yang actionable. Dalam konteks kualitas air, pendekatan probabilistik memungkinkan kuantifikasi ketidakpastian prediksi yang kritis sebelum rekomendasi perbaikan dibangkitkan, sementara framework DiCE menyediakan arah perubahan spesifik pada parameter fisikokimia yang dapat diintervensi secara operasional.

3.1. Jadwal Gambaran Umum Alur Pemodelan


Seluruh alur yang akan digambarkan pada Gambar 3.1 direncanakan untuk diimplementasikan dalam lingkungan simulasi berbasis komputasi awan menggunakan Google Colab dengan runtime Python 3.9+. Spesifikasi lingkungan meliputi akses ke GPU/TPU akselerasi untuk mempercepat hyperparameter tuning pada NGBoost, serta memori RAM minimal 12 GB untuk menampung dataset dan hasil pembangkitan counterfactual secara simultan. Pustaka utama yang digunakan meliputi NGBoost untuk pemodelan probabilistik, dice-ml untuk pembangkitan counterfactual, serta scikit-learn, pandas, numpy, matplotlib, dan seaborn untuk preprocessing, evaluasi, dan visualisasi. Skenario uji dibagi menjadi dua fase: Fase A meliputi pelatihan dan evaluasi model NGBoost menggunakan data uji yang belum pernah dilihat selama training; Fase B meliputi pembangkitan counterfactual dengan DiCE terhadap instance yang diprediksi sebagai Tidak Layak pada Fase A, dengan konfigurasi $k = 4$ hingga $k = 5$ alternatif rekomendasi per instance. Parameter DiCE meliputi bobot proximity, diversity, dan sparsity yang diseimbangkan melalui fungsi loss multi-objective, dengan batasan iterasi maksimal untuk mencegah optimasi tanpa konvergensi. Tidak diperlukan hardware khusus, sensor, maupun perangkat Internet of Things karena dataset yang digunakan bersifat tabular dan statis. Sebagai ilustrasi yang lebih rinci mengenai proses yang dilakukan, berikut dicantumkan arsitektur umum dalam bentuk alur diagram:



Gambar 3.1 Alur Diagram Pemodelan Fase Awal (Sumber: Peneliti).



Gambar 3.2 Alur Diagram Pemodelan Fase A (Sumber: Peneliti).



Gambar 3.3 Alur Diagram Pemodelan Fase B (akhir) (Sumber: Peneliti).

Diagram tersebut memperlihatkan tahapan-tahapan mulai dari pengumpulan data, pra-pemrosesan, pemodelan NGBBoost, pembangkitan rekomendasi preskriptif dengan DiCE, hingga evaluasi model dan kualitas counterfactual. Proses diawali dengan eksplorasi dataset kualitas air yang dilanjutkan dengan penanganan nilai hilang, pembagian data, penskalaan fitur, serta resampling kondisional. Tahap pemodelan dilakukan dengan melatih NGBBoost untuk menghasilkan probabilitas prediksi yang terkalibrasi. Selanjutnya, instance yang diprediksi sebagai Tidak Layak diproses dengan DiCE untuk membangkitkan himpunan counterfactual yang merepresentasikan skenario perbaikan kualitas air. Setiap tahapan dilengkapi dengan mekanisme umpan balik untuk penyetelan parameter dan pengecekan konvergensi.

3.2. Pengumpulan Data

Pengumpulan data pada penelitian ini dilakukan menggunakan dataset sekunder berformat tabular yang tersedia secara publik, yaitu Water Potability Dataset yang diperoleh dari platform Kaggle. Dataset tersebut dipilih karena telah digunakan secara luas sebagai benchmark dalam lebih dari 99 publikasi terindeks Scopus, termasuk Patel et al. (2022) dan Park et al. (2022) [8][3]. Dataset diposisikan sebagai benchmark untuk validasi kerangka metodologi yang diusulkan, bukan sebagai representasi kondisi kualitas air lapangan tertentu. Kontribusi utama penelitian terletak pada kerangka kerja NGBBoost dan DiCE yang bersifat transferable dan dapat diaplikasikan pada dataset kualitas air tabular apapun, termasuk data dari laboratorium resmi maupun instansi pengelola air minum. Secara teknis, dataset terdiri atas 3.276 baris sampel dengan 9 fitur, yaitu pH, Hardness, Solids, Chloramines, Sulfate, Conductivity, Organic_carbon, Trihalomethanes, dan Turbidity, serta 1 variabel target biner, yaitu Potability, dengan nilai 0 menunjukkan kondisi tidak layak konsumsi dan nilai 1 menunjukkan kondisi layak konsumsi. Seluruh record digunakan karena memiliki variabel target (Potability) yang valid dan tidak ditemukan record duplikat maupun record dengan seluruh fitur yang missing. Record dengan missing values parsial (pH: 14,98%, Sulfate: 23,84%, Trihalomethanes: 4,95%) tetap dipertahankan karena akan ditangani pada tahap imputasi MICE. Dataset ini juga memiliki karakteristik yang relevan terhadap proses pemodelan, yaitu adanya missing values pada beberapa fitur, terutama pH, Sulfate, dan Trihalomethanes, serta distribusi kelas yang tidak seimbang, dengan proporsi sekitar 61% untuk kelas tidak layak dan 39% untuk kelas layak. Selain itu, dataset bersifat statis dan tidak berasal dari pengukuran sensor real-time atau sistem IoT, sehingga sesuai dengan batasan penelitian yang telah ditetapkan.

3.3. Preprocessing Data

Tahap preprocessing dilakukan untuk menyiapkan dataset agar memenuhi syarat input bagi algoritma pemodelan. Proses ini terdiri atas lima sub-tahapan yang dieksekusi secara sekuensial dengan urutan yang ketat untuk mencegah data leakage: (1) Exploratory Data Analysis untuk memahami karakteristik data, (2)

penanganan missing values menggunakan MICE sebelum pembagian data karena MICE memerlukan seluruh observasi untuk estimasi korelasi multivariat, (3) stratified split menjadi data latih (70%), data validasi (15%), dan data uji (15%) yang dilakukan sebelum feature scaling, (4) feature scaling dengan parameter μ dan σ yang dihitung hanya dari data latih kemudian ditransformasikan pada data validasi dan data uji, serta (5) penanganan class imbalance menggunakan SMOTE-ENN yang diterapkan hanya pada data latih yang telah diskalakan. Urutan ini mengikuti best practice *machine learning* untuk memastikan tidak ada informasi dari data evaluasi yang terbawa ke dalam proses training [3], [4].

3.3.1. Exploratory Data Analysis (EDA)

Tabel 3.1 Statistik Deskriptif Dataset

Parameter	Count	Mean	Std	Min	Max	Missing (%)
pH	2785	7.0808	1.5943	0.0000	14.0000	14.99%
Hardness	3276	196.3695	32.8798	47.4320	323.1240	0.00%
Solids (TDS)	3276	22014.0925	8768.5708	320.9426	61227.1960	0.00%
Chloramines	3276	7.1223	1.5831	0.3520	13.1270	0.00%
Sulfate	2495	333.7758	41.4168	129.0000	481.0306	23.84%
Conductivity	3276	426.2051	80.8241	181.4838	753.3426	0.00%
Organic_carbon	3276	14.2850	3.3082	2.2000	28.3000	0.00%
Trihalomethanes	3276	66.3963	16.1750	0.7380	124.0000	4.95%
Turbidity	3276	3.9668	0.7804	1.4500	6.7390	0.00%

Tahap EDA dilakukan untuk memahami karakteristik awal dataset sebelum proses pemodelan. Analisis mencakup pemeriksaan struktur data, identifikasi jumlah dan jenis fitur, distribusi nilai pada setiap variabel, deteksi missing values, serta pengamatan terhadap kemungkinan adanya nilai ekstrem atau outlier. Distribusi variabel target juga dianalisis untuk mengetahui komposisi kelas pada data potability. Hasil EDA menjadi dasar penentuan strategi preprocessing selanjutnya.

3.3.2. Penanganan Missing values

Nilai hilang terutama ditemukan pada fitur pH, Sulfate, dan Trihalomethanes. Untuk mengatasinya, diimplementasikan metode Multivariate Imputation by Chained Equations (MICE), yaitu pendekatan imputasi berbasis regresi iteratif yang memanfaatkan hubungan antarfitur dalam memperkirakan nilai yang hilang. Metode ini dipilih karena karakteristik fitur pada dataset kualitas air tidak sepenuhnya independen secara kimiawi, sehingga imputasi berbasis statistik sederhana berpotensi mengabaikan relasi antarvariabel. Imputasi dilakukan pada

seluruh dataset sebelum pembagian data untuk memastikan konsistensi struktur data.

3.3.3. Train-Test Split

Dataset dibagi menjadi tiga subset: data latih, data validasi, dan data uji, dengan proporsi 70:15:15 menggunakan stratified split agar proporsi kelas tetap merepresentasikan distribusi asli. Pembagian ini dilakukan sebelum penskalaan fitur dan resampling untuk mencegah data leakage, sehingga informasi dari data uji tidak terbawa ke dalam proses estimasi parameter scaling maupun pembentukan sampel sintetik.

3.3.4. Feature scaling

Penskalaan diperlukan untuk menyeragamkan skala antarfitur. Metode standardization diterapkan dengan persamaan:

$$z = \frac{x - \mu}{\sigma}$$

dengan x sebagai nilai asli fitur, μ sebagai rata-rata, dan σ sebagai simpangan baku. Parameter μ dan σ dihitung hanya dari data latih, kemudian diterapkan pada data validasi dan data uji. Penskalaan dilakukan sebelum penanganan class imbalance karena algoritma SMOTE-ENN bersifat sensitif terhadap perbedaan skala fitur; fitur dengan rentang nilai yang lebih besar akan mendominasi pembentukan sampel sintetik dan proses nearest neighbor pada SMOTE-ENN, sehingga hasil resampling menjadi bias..

3.3.5. Penanganan *Class imbalance*

Teknik SMOTE-ENN dipertimbangkan secara kondisional berdasarkan hasil EDA yang menunjukkan ketidakseimbangan proporsi antarkelas. SMOTE-ENN merupakan pendekatan hibrida yang menggabungkan oversampling kelas minoritas dan undersampling sampel noise di area batas keputusan. Penerapan dibatasi hanya pada data latih yang telah diskalakan untuk mencegah data leakage dan memastikan stabilitas pembentukan sampel sintetik. Apabila baseline menunjukkan performa memadai tanpa resampling, dataset asli tetap digunakan.

3.4. Pemodelan NGBoost

3.4.1. Konfigurasi Model NGBoost

Natural Gradient Boosting (NGBoost) merupakan paradigma pembelajaran mesin probabilistik yang memodelkan distribusi penuh $P(y | x)$ sebagai output prediksi, bukan sekadar nilai ekspektasi tunggal. Mekanisme inti yang membedakan NGBoost dari metode boosting konvensional terletak pada penggunaan Natural Gradient untuk update parameter distribusi. Berbeda dengan gradient descent standar yang beroperasi pada ruang Euclidean, Natural Gradient memanfaatkan Fisher Information Matrix untuk mengarahkan proses optimasi sesuai dengan geometri ruang parameter distribusi. Pendekatan ini memberikan arah update yang lebih representatif terhadap struktur statistik data, sehingga

estimasi parameter distribusi menjadi lebih stabil terutama pada dataset dengan dimensi fitur yang bervariasi dan sampel yang memiliki karakteristik heterogen.

Pemilihan NGBoost pada penelitian ini didukung oleh keberhasilan pendekatan probabilistik tersebut pada berbagai domain. Pada domain finansial, Zhu et al. (2023) menunjukkan bahwa NGBoost yang diintegrasikan dengan SMOTE-ENN mampu mencapai akurasi 97.18% dengan distribusi probabilitas yang terkalibrasi [6]. Duan et al. (2020) sebagai pengembang NGBoost mendemonstrasikan performa kompetitif terhadap Monte Carlo Dropout dan Deep Ensembles pada benchmark regresi dan klasifikasi [7]. Relevansi tersebut ditransfer ke domain kualitas air, di mana parameter fisikokimia memiliki variabilitas alami antar sampel yang memerlukan estimasi ketidakpastian untuk mendukung pengambilan keputusan yang andal.

3.4.2. Distribusi Output untuk Klasifikasi Biner

Untuk variabel target Potability yang bersifat biner, distribusi output pada NGBoost ditentukan dengan menggunakan Bernoulli Distribution sebagai parameterisasi prediksi. Parameter utama yang diestimasi oleh model adalah probabilitas kejadian kelas positif, dilambangkan sebagai $\mu = P(y = 1 | x)$, yang merepresentasikan tingkat keyakinan model bahwa sampel air dengan fitur fisikokimia tertentu tergolong Layak. Nilai μ berada pada rentang $[0,1]$. Pada klasifikasi biner dengan distribusi Bernoulli, informasi ketidakpastian inheren tercermin secara natural dalam nilai probabilitas itu sendiri. Secara matematis, variance pada distribusi Bernoulli ditentukan oleh $\mu(1 - \mu)$, sehingga ketika nilai probabilitas mendekati ambang keputusan konvensional yaitu 0,5, ketidakpastian prediksi mencapai titik maksimal.

Output prediksi dari model bukan berupa label klasifikasi hard secara langsung, melainkan nilai probabilitas kontinu untuk setiap instance. Penentuan label klasifikasi dilakukan dengan menerapkan ambang konvensional, di mana instance dengan $\mu \geq 0,5$ dikategorikan sebagai Layak dan instance dengan $\mu < 0,5$ dikategorikan sebagai Tidak Layak. Nilai probabilitas kontinu tetap disimpan bersama fitur input untuk keperluan analisis ketidakpastian dan integrasi dengan tahap preskriptif.

3.4.3. Konfigurasi dan Training

Konfigurasi model NGBoost ditetapkan berdasarkan serangkaian hyperparameter yang mengendalikan kompleksitas pembelajaran, kecepatan konvergensi, serta stabilitas estimasi parameter distribusi. Hyperparameter utama yang dikonfigurasi meliputi jumlah iterasi boosting, learning rate, proporsi sampel untuk estimasi gradient stokastik, serta kompleksitas base learner berupa decision tree dangkal. Strategi tuning dilakukan dengan memanfaatkan data validasi sebesar 15% yang telah dipisahkan pada tahap train-test split. Beberapa kombinasi hyperparameter diuji secara prosedural, di mana setiap konfigurasi dievaluasi berdasarkan dua kriteria utama, yaitu Negative Log-Likelihood (NLL) dan Expected Calibration Error (ECE). NLL dihitung sebagai ukuran kesesuaian antara

probabilitas prediksi dengan distribusi aktual kelas, sedangkan ECE mengukur tingkat kalibrasi model dengan membandingkan rata-rata probabilitas prediksi pada setiap bin dengan proporsi aktual kelas positif pada bin yang bersesuaian.

Kriteria pemilihan konfigurasi final didasarkan pada trade-off antara penurunan NLL dan stabilisasi ECE pada data validasi. Konfigurasi optimal dipilih sebagai kombinasi yang menghasilkan keduanya dalam kondisi seimbang. Mekanisme early stopping diterapkan pada proses training untuk mencegah overfitting, di mana iterasi boosting dihentikan ketika stabilisasi NLL pada data validasi tidak menunjukkan penurunan signifikan pada iterasi-iterasi berikutnya.

3.4.4. Proses Training dan Prediksi

Proses training NGBoost dilakukan pada data latih yang telah melalui seluruh tahapan preprocessing. Input training terdiri atas sembilan fitur fisikokimia yang telah dinormalisasi, dengan variabel target berupa label biner Potability. Proses fitting dilakukan secara iteratif dengan inialisasi parameter distribusi Bernoulli untuk setiap instance. Pada setiap iterasi boosting, base learner berupa decision tree dangkal dilatih untuk memprediksi arah update terhadap parameter distribusi. Update parameter dihitung menggunakan Natural Gradient yang diperoleh dari Fisher Information Matrix, sehingga perubahan parameter mengikuti geometri ruang distribusi. Estimasi probabilitas kelas positif diperbarui secara sekuensial pada setiap iterasi hingga kondisi konvergensi atau early stopping tercapai.

Output dari proses training adalah model terkalibrasi yang mampu menghasilkan distribusi probabilitas Bernoulli untuk setiap instance. Pada tahap prediksi, model menerima fitur input dari data uji dan mengeluarkan nilai probabilitas kelas positif. Instance yang diprediksi sebagai Tidak Layak beserta fitur-fitur fisikokimianya dan nilai probabilitas prediksinya menjadi input utama pada tahap pembangkitan rekomendasi preskriptif dengan framework DiCE. Instance dengan probabilitas prediksi mendekati ambang keputusan secara inheren memiliki ketidakpastian yang lebih tinggi, sehingga perubahan relatif kecil pada fitur berpotensi mengubah prediksi kelas dan menghasilkan rekomendasi yang lebih realistis untuk diimplementasikan.

3.4.5. Baseline Model

Baseline model disusun sebagai acuan komparatif prosedural untuk mengukur kontribusi pendekatan probabilistik NGBoost dalam konteks klasifikasi kualitas air. Dua algoritma baseline dipilih berdasarkan keluasan penggunaannya pada domain kualitas air dan karakteristik pembelajaran yang kontras dengan NGBoost, yaitu XGBoost sebagai representasi gradient boosting deterministik yang menghasilkan probabilitas point estimate tanpa memodelkan struktur distribusi penuh, serta Random Forest sebagai representasi ensemble deterministik berbasis bagging yang menghasilkan prediksi melalui agregasi multiple decision trees. Kedua baseline tersebut telah umum diterapkan pada penilaian kualitas air, sehingga pemilihannya relevan secara domain.

Prosedur training baseline dilaksanakan pada data latih yang identik dengan kondisi yang digunakan untuk NGBoost, meliputi hasil imputasi, stratified split, standardization, serta resampling kondisional sesuai tahapan preprocessing. Keseragaman kondisi input diperlukan untuk memastikan perbandingan yang adil, di mana perbedaan performa dapat diatribusikan pada karakteristik algoritma. Perbedaan esensial antara baseline dan NGBoost terletak pada representasi output. Baseline menghasilkan probabilitas point estimate tanpa estimasi ketidakpastian atau distribusi penuh, sehingga tidak memungkinkan identifikasi instance yang memiliki keyakinan prediksi rendah di dekat ambang keputusan. Keterbatasan tersebut mengurangi kelayakan baseline sebagai fondasi tunggal bagi rekomendasi preskriptif.

Analisis komparatif dilakukan dengan membandingkan performa NGBoost terhadap kedua baseline berdasarkan dua dimensi evaluasi: (1) dimensi klasifikasi meliputi Accuracy, Precision, Recall, dan F1-Score pada data uji, serta (2) dimensi probabilistik meliputi Negative Log-Likelihood (NLL) dan Expected Calibration Error (ECE) pada data uji. Perbandingan ini bertujuan menjawab pertanyaan apakah pendekatan probabilistik (NGBoost) memberikan nilai tambah yang signifikan dibandingkan pendekatan deterministik konvensional yang telah digunakan pada literatur sebelumnya [3], [8]. Hasil komparasi menjadi justifikasi pemilihan NGBoost sebagai fondasi bagi tahap preskriptif (Fase B), di mana model dengan kalibrasi terbaik akan digunakan sebagai input untuk pembangunan counterfactual oleh DiCE.

3.5. Implementasi Diverse *Counterfactual explanations*

3.5.1. Konfigurasi DiCE

Tahap preskriptif pada penelitian ini dibangun dengan menggunakan framework *Diverse Counterfactual explanations* (DiCE) untuk menghasilkan rekomendasi perbaikan kualitas air yang actionable. Berbeda dengan pendekatan *explainability* pasif yang hanya menjelaskan faktor-faktor apa saja yang memengaruhi prediksi model, counterfactual explanation menjawab pertanyaan mengenai bagaimana kondisi input harus diubah agar prediksi kelas berubah menjadi keadaan yang diinginkan. Pendekatan tersebut secara inheren bersifat preskriptif karena memberikan arah perubahan spesifik pada fitur yang dapat diintervensi secara operasional.

Framework DiCE membangkitkan counterfactual melalui pendekatan optimasi berbasis gradient dengan fungsi loss yang meminimalkan lima properti secara simultan: *validity* untuk memastikan perubahan kelas prediksi terjadi, *proximity* untuk menjaga kedekatan dengan instance asli di ruang fitur, *sparsity* untuk membatasi jumlah fitur yang diubah agar intervensi lebih praktis, *diversity* untuk menghasilkan alternatif rekomendasi yang tidak identik, serta *feasibility* untuk menjamin nilai fitur hasil berada dalam rentang yang dapat dicapai secara fisik.

Secara teori, framework DiCE mendukung pembangkitan counterfactual bidirectional dari kelas manapun ke kelas manapun. Namun demikian, dalam konteks domain kualitas air pada penelitian ini, fokus implementasi diarahkan pada perubahan dari kelas Tidak Layak ke kelas Layak karena secara operasional lebih actionable dalam konteks manajemen air. Arah sebaliknya dapat diterapkan untuk analisis sensitivitas parameter namun tidak menjadi fokus implementasi.

3.5.2. Konfigurasi Constraints Domain

Pembangkitan counterfactual pada domain kualitas air memerlukan batasan nilai fitur yang sesuai dengan karakteristik fisik dan regulasi air minum untuk menjamin *feasibility* rekomendasi. Constraints domain ditetapkan meliputi permitted range untuk setiap parameter fisikokimia berdasarkan standar kelayakan air minum, penetapan fitur yang bersifat immutable (tidak dapat diubah secara operasional), serta batasan perubahan antarfitur yang memiliki korelasi kimiawi. Rentang nilai yang diperbolehkan memastikan bahwa counterfactual yang dihasilkan tidak mengusulkan kondisi yang tidak mungkin dicapai dalam praktik pengolahan air, sedangkan fitur immutable dipertahankan untuk menjaga konsistensi karakteristik sampel yang tidak dapat diintervensi. Konfigurasi constraints tersebut diintegrasikan ke dalam fungsi optimasi DiCE sehingga proses pembangkitan counterfactual menghasilkan rekomendasi yang tidak hanya valid secara prediktif, tetapi juga feasible secara domain. Berikut adalah Feasibility constraints berdasarkan Permenkes No. 2/2023, [21] (primary) beserta WHO Guidelines 2022 (komplementer untuk Conductivity dan Organic Carbon) [20].

Tabel 3.2 Constraint GENERATION berdasarkan WHO Guidelines 2022

Parameter	WHO Guideline	Permitted Range DiCE	Catatan
pH	6.5 – 8.5	6.5 – 8.5	Sama dengan Permenkes
Hardness	< 500 mg/L	0 – 500	Acceptability (bukan health-based)
TDS (Solids)	< 1000 mg/L	0 – 1000	Taste; tidak ada health concern
Chloramines	≤ 3 mg/L	0 – 3	Guideline value
Sulfate	< 500 mg/L	0 – 500	Tidak ada health-based GV
Conductivity	Tidak ada GV formal	181 – 753 (data-driven)	P5-P95 dari training data
Organic Carbon	Tidak ada GV formal	2.2 – 28.3 (data-driven)	P5-P95 dari training data

Trihalomethanes	$\leq 200 \mu\text{g/L}$ (total THMs)	0 – 200	Jumlah 4 THMs
Turbidity	$< 4 \text{ NTU}$ (disinfection)	0 – 4	Idealnya $< 1 \text{ NTU}$

Tabel 3.3 Constraint EVALUASI berdasarkan Permenkes No. 2 Tahun 2023

Parameter	Permenkes Aktual	Sumber	Status di Dataset
pH	6.5 – 8.5	Permenkes No. 2/2023 Lampiran I	Banyak di luar range (min 0, max 14)
TDS (Solids)	$< 300 \text{ mg/L}$	Permenkes No. 2/2023 Lampiran I	SELURUH data melebihi (min 321)
Kekeruhan/Turbidity	$< 3 \text{ NTU}$	Permenkes No. 2/2023 Lampiran I	Sebagian melebihi (max 6.74)
Sisa Klor/Chloramines	0.2 – 0.5 mg/L	Permenkes No. 2/2023 Lampiran I	Hampir semua melebihi (mean 7.12)
Hardness	TIDAK ADA	Tidak diatur dalam Permenkes	Gunakan WHO
Sulfate	TIDAK ADA	Tidak diatur dalam Permenkes	Gunakan WHO
Conductivity	TIDAK ADA	Tidak di Tabel Wajib/Khusus	Gunakan data-driven
Organic Carbon	TIDAK ADA	Tidak diatur dalam Permenkes	Gunakan data-driven
Trihalomethanes	TIDAK ADA	Tidak diatur dalam Permenkes	Gunakan WHO

3.5.3. Proses Generate Counterfactual

Proses pembangkitan counterfactual dimulai dengan memilih instance dari data uji yang diprediksi sebagai Tidak Layak oleh model NGBoost sebagai input utama. Instance tersebut bersama dengan fitur-fitur fisikokimianya dan nilai probabilitas prediksinya diserahkan ke framework DiCE untuk menghasilkan set counterfactual yang mengubah prediksi kelas menjadi Layak. Fungsi optimasi pada DiCE diterapkan dengan bobot yang menyeimbangkan *validity*, *proximity*, *sparsity*, *diversity*, dan *feasibility* sesuai constraints domain yang telah dikonfigurasi sebelumnya. Optimizer berbasis gradient mencari nilai fitur alternatif di ruang fitur yang telah diskalakan, sehingga perubahan yang dihasilkan dapat diinterpretasikan kembali ke nilai asli setelah proses inverse scaling.

Apabila counterfactual yang dihasilkan tidak memenuhi constraints domain atau tidak menghasilkan prediksi kelas Layak, maka constraints dilonggarkan

secara bertahap hingga solusi feasible ditemukan. Demikian pula, apabila set counterfactual yang dihasilkan tidak memenuhi ambang validity, bobot optimizer pada fungsi loss DiCE disesuaikan untuk meningkatkan prioritas terhadap validity pada iterasi pembangkitan berikutnya. Proses ini berulang hingga diperoleh himpunan counterfactual yang valid.

Output dari tahap ini berupa set counterfactual yang valid, yaitu instance-instance alternatif yang memenuhi constraints domain dan menghasilkan prediksi Layak dari model NGBoost. Setiap counterfactual dalam set tersebut merepresentasikan satu skenario rekomendasi perbaikan dengan kombinasi perubahan fitur yang berbeda, sehingga tersedia beberapa alternatif tindakan operasional untuk meningkatkan kelayakan air. Hasil tersebut selanjutnya dievaluasi menggunakan metrik counterfactual quality untuk mengukur sejauh mana rekomendasi yang dihasilkan memenuhi kriteria realisme dan keberagaman.

3.5.4. Evaluasi Model Prediktif

Evaluasi model prediktif dilakukan untuk mengukur kemampuan klasifikasi dan kualitas kalibrasi probabilitas dari model NGBoost serta baseline. Metrik klasifikasi yang digunakan meliputi Accuracy, Precision, Recall, dan F1-Score untuk mengukur performa diskriminatif model dalam membedakan kelas Layak dan Tidak Layak. Selain metrik klasifikasi, Negative Log-Likelihood (NLL) dihitung sebagai ukuran kesesuaian antara probabilitas prediksi dengan distribusi aktual kelas, di mana nilai yang lebih rendah mengindikasikan model yang lebih mampu memprediksi probabilitas yang mendekati frekuensi kejadian sebenarnya. Kalibrasi model diukur menggunakan Calibration Curve dan Expected Calibration Error (ECE) dengan membandingkan rata-rata probabilitas prediksi pada setiap bin dengan proporsi aktual kelas positif pada bin yang bersesuaian. Evaluasi tersebut dilakukan pada data uji yang belum pernah dilihat selama training dan tuning untuk memperoleh estimasi performa yang tidak bias.

3.5.5. Evaluasi Counterfactual

Evaluasi counterfactual dilakukan untuk mengukur kualitas rekomendasi preskriptif yang dihasilkan oleh framework DiCE. Lima properti utama dievaluasi: *Validity* untuk mengukur proporsi counterfactual yang berhasil mengubah prediksi kelas menjadi Layak; *Proximity* untuk mengukur kedekatan counterfactual dengan instance asli di ruang fitur; *Sparsity* untuk menghitung jumlah fitur yang diubah pada setiap counterfactual; *Diversity* untuk mengukur perbedaan antar counterfactual dalam satu set rekomendasi; serta *Feasibility* untuk memastikan nilai fitur hasil berada dalam rentang yang diperbolehkan oleh constraints domain. Evaluasi tersebut dilakukan pada set counterfactual yang dihasilkan dari instance Tidak Layak pada data uji untuk menjawab sejauh mana rekomendasi DiCE memenuhi kriteria realisme dan keberagaman yang diperlukan untuk implementasi operasional.

3.6. Tools dan Lingkungan Pengembangan

Implementasi penelitian direncanakan menggunakan bahasa pemrograman Python versi 3.9 ke atas pada lingkungan pengembangan berbasis komputasi awan (cloud computing) menggunakan Google Colab. Pemilihan Google Colab didasarkan pada ketersediaan akses GPU untuk mempercepat proses hyperparameter tuning serta kapasitas memori RAM minimal 12 GB untuk menampung dataset dan hasil pembangkitan counterfactual secara simultan. Tabel 3.3 menyajikan spesifikasi tools dan pustaka (library) yang digunakan dalam penelitian ini.

Tabel 3.4 Tools dan Lingkungan Pengembangan yang digunakan

Tools	Versi	Fungsi	Lisensi
Python	3.9+	Bahasa pemrograman utama	PSF License
Google Colab	Runtime	Lingkungan eksekusi (GPU/TPU)	Free
NGBoost	latest	Pemodelan probabilistik Natural Gradient Boosting	Apache 2.0
dice-ml	latest	Pembangkitan Diverse Counterfactual Explanations	MIT
scikit-learn	latest	Preprocessing, model baseline (XGBoost, Random Forest), evaluasi	BSD-3
pandas	latest	Manipulasi dan analisis data tabular	BSD-3
numpy	latest	Komputasi numerik dan operasi array	BSD-3
matplotlib	latest	Visualisasi grafik dan calibration curve	PSF
seaborn	latest	Visualisasi statistik dan distribusi data	BSD-3
imbalanced-learn	latest	Penanganan class imbalance (SMOTE-ENN)	MIT

Seluruh library yang digunakan berlisensi open-source (Apache 2.0, MIT, atau BSD-3) sehingga tidak memerlukan izin khusus dari pengembang. Reproducibility eksperimen dijamin melalui penggunaan random seed yang konsisten pada seluruh proses training dan evaluasi, serta dokumentasi versi library

yang digunakan. Tidak diperlukan hardware khusus, sensor, maupun perangkat Internet of Things karena dataset yang digunakan bersifat tabular dan statis.

DAFTAR PUSTAKA

- [1] “WHO, UNICEF, and World Bank, ‘State of the World’s Drinking Water: An Urgent Call to Action to Accelerate Progress on Ensuring Safe Drinking Water for All,’ Geneva: World Health Organization, 2022. ISBN: 978-92-4-006080-7.”, Accessed: Jun. 14, 2026. [Online]. Available: <https://www.who.int/publications/i/item/9789240060807>
- [2] B. Aslam, A. Maqsoom, A. H. Cheema, F. Ullah, A. Alharbi, and M. Imran, “Water Quality Management Using Hybrid Machine Learning and Data Mining Algorithms: An Indexing Approach,” *IEEE Access*, vol. 10, pp. 119692–119705, 2022, doi: 10.1109/ACCESS.2022.3221430.
- [3] J. Park, W. H. Lee, K. T. Kim, C. Y. Park, S. Lee, and T.-Y. Heo, “Interpretation of ensemble learning to predict water quality using explainable artificial intelligence,” *Science of The Total Environment*, vol. 832, p. 155070, Aug. 2022, doi: 10.1016/j.scitotenv.2022.155070.
- [4] M. Barrabes, M. Perera, V. Novelle Moriano, X. Giro-I-Nieto, D. Mas Montserrat, and A. G. Ioannidis, “Advances in Biomedical Missing Data Imputation: A Survey,” *IEEE Access*, vol. 13, pp. 16918–16932, 2025, doi: 10.1109/ACCESS.2024.3516506.
- [5] A. Al Bataineh, B. Vamsi, and S. Alan Smith, “A Hybrid Machine Learning Framework for Water Quality Index Prediction Using Feature-Based Neural Network Initialization,” *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, pp. 1–25, Jan. 2026, doi: 10.1109/JSTARS.2026.3654017.
- [6] Y. Zhu, Y. Hu, Q. Liu, H. Liu, C. Ma, and J. Yin, “A Hybrid Approach for Predicting Corporate Financial Risk: Integrating SMOTE-ENN and NGBoost,” *IEEE Access*, vol. 11, pp. 111106–111125, 2023, doi: 10.1109/ACCESS.2023.3323198.
- [7] T. Duan *et al.*, “NGBoost: Natural Gradient Boosting for Probabilistic Prediction,” 2020. doi: 10.48550/arXiv.1910.03225.
- [8] J. Patel *et al.*, “A Machine Learning-Based Water Potability Prediction Model by Using Synthetic Minority Oversampling Technique and Explainable AI,” *Comput. Intell. Neurosci.*, vol. 2022, pp. 1–15, Sep. 2022, doi: 10.1155/2022/9283293.
- [9] I. A. Aderemi, T. O. Kehinde, U. Daniel Okwor, K. H. Ahmad, K. Y. Adjei, and C. Cyriacus Ekechi, “Explainable AI for Water Quality Monitoring: A Systematic Review of Transparency, Interpretability, and Trust,” *IEEE Sensors Reviews*, vol. 2, pp. 419–443, Aug. 2025, doi: 10.1109/SR.2025.3595500.

- [10] L. C. Nnadi, C. P. Isiwu, D. Ding, D. M. Muepu, and Y. Watanobe, "Multi-Level Explainable AI for Predicting Student Depression Risk: Global, Subgroup, and Individual Insights," *IEEE Access*, vol. 14, pp. 6271–6286, Jan. 2026, doi: 10.1109/ACCESS.2026.3652631.
- [11] X. Dastile and T. Celik, "Counterfactual Explanations with Multiple Properties in Credit Scoring," *IEEE Access*, vol. 12, pp. 110713–110728, 2024, doi: 10.1109/ACCESS.2024.3441037.
- [12] M. YURTSEVER and M. EMEÇ, "Potable Water Quality Prediction Using Artificial Intelligence and Machine Learning Algorithms for Better Sustainability," *Ege Akademik Bakis (Ege Academic Review)*, Mar. 2023, doi: 10.21121/eab.1252167.
- [13] M. Lenatti, A. Carlevaro, A. Guergachi, K. Keshavjee, M. Mongelli, and A. Paglialonga, "Estimation and Conformity Evaluation of Multi-Class Counterfactual Explanations for Chronic Disease Prevention," *IEEE J. Biomed. Health Inform.*, vol. 29, no. 9, pp. 6132–6142, 2025, doi: 10.1109/JBHI.2024.3492730.
- [14] A. Ferrario and M. Loi, "The Robustness of Counterfactual Explanations Over Time," *IEEE Access*, vol. 10, pp. 82736–82750, 2022, doi: 10.1109/ACCESS.2022.3196917.
- [15] M. Suffian, P. Graziani, J. M. Alonso, and A. Bogliolo, "FCE: Feedback Based Counterfactual Explanations for Explainable AI," *IEEE Access*, vol. 10, pp. 72363–72372, 2022, doi: 10.1109/ACCESS.2022.3189432.
- [16] B. Meulemeester, R. M. B. De Oliveira, and D. Martens, "Calculating and Visualizing Counterfactual Feature Importance Values," Jun. 2023, doi: 10.1109/ACCESS.2026.3679213.
- [17] A. Carlevaro, M. Lenatti, A. Paglialonga, and M. Mongelli, "Multiclass Counterfactual Explanations Using Support Vector Data Description," *IEEE Transactions on Artificial Intelligence*, vol. 5, no. 6, pp. 3046–3056, Jun. 2024, doi: 10.1109/TAI.2023.3337053.
- [18] G. Li, B. Li, C. Li, K. Zeng, S. Wang, and P. Chen, "Battery State of Charge Probabilistic Estimation Using Natural Gradient Boosting," *IEEE Transactions on Industrial Electronics*, vol. 71, no. 9, pp. 10636–10646, Sep. 2024, doi: 10.1109/TIE.2023.3331136.
- [19] A. Alshami, E. Ali, M. Elsayed, A. E. E. Eltoukhy, and T. Zayed, "IoT Innovations in Sustainable Water and Wastewater Management and Water Quality Monitoring: A Comprehensive Review of Advancements, Implications, and Future Directions," *IEEE Access*, vol. 12, pp. 58427–58453, 2024, doi: 10.1109/ACCESS.2024.3392573.

- [20] “Guidelines for Drinking-Water Quality”, Accessed: Jun. 14, 2026.
[Online]. Available:
<https://www.who.int/publications/i/item/9789240045064>
- [21] “Kementerian Kesehatan Republik Indonesia, ‘Peraturan Menteri Kesehatan Nomor 2 Tahun 2023 tentang Peraturan Pelaksanaan Peraturan Pemerintah Nomor 66 Tahun 2014 tentang Kesehatan Lingkungan,’ Berita Negara Republik Indonesia No. 55, 2023.”.

LAMPIRAN

Data-data pendukung, *curriculum vitae*(CV) untuk pembimbing dari luar Universitas Telkom, dsb.